

Corrective RAG Híbrido para generación fundamentada sobre plantas medicinales Peruanas

Ower Lopez-Arela^[0009-0008-1075-4275], Daniel
Marron-Carcausto^[0009-0008-5964-0201], and Antonio
Arroyo-Paz^[0000-0003-1838-4527]

Escuela Profesional de Ingeniería de Sistemas, Universidad Nacional de San Agustín
de Arequipa, Perú
`{olopeza, dmarron, aarroyop}@unsa.edu.pe`

Resumen La vasta literatura existente sobre las plantas medicinales del Perú sufre un grave problema de fragmentación. Al estar repartida entre numerosos repositorios, extraer evidencia farmacológica real resulta costoso. Para hacer frente a esto, proponemos SIRCA-RAG (Sistema para la Recuperación Inteligente y Respuestas Correctivas), una arquitectura bilingüe diseñada para unificar dicha evidencia mediante técnicas correctivas. Nuestra solución fusiona búsquedas densas con léxicas (BM25) usando *Reciprocal Rank Fusion*, y luego aplica un reordenador cruzado (*cross-encoder*) que termina siendo vital para proteger la exactitud de las respuestas. Un enrutador tipo CRAG gestiona la calidad final. Evaluamos la herramienta en un entorno real con 16,486 artículos (cubriendo 100 especies locales), logrando una Fidelidad de 0,554 y un MRR de 0,862. También demostramos empíricamente que la normalización por defecto arruina los enrutamientos; tuvimos que forzar una calibración sigmoide absoluta para que las derivaciones hacia búsqueda externa funcionaran de forma legítima.

Keywords: Retrieval-Augmented Generation (RAG) · Etnobotánica Peruana · Modelos de Lenguaje Grande (LLM) · Recuperación Híbrida · Procesamiento de Lenguaje Natural (NLP)

1. Introducción

Sabemos que el Perú posee cerca de 25,000 especies vegetales, y al menos entre 1,400 y 5,000 gozan de algún grado de evidencia farmacológica [3,2]. Sin embargo, si un investigador quiere rastrear datos específicos sobre *Uncaria tomentosa* o *Croton lechleri*, pronto se topará con el problema central: los datos no están en un solo lugar. Las publicaciones se hallan regadas por todo PubMed, así como en bases de biodiversidad locales y registros internacionales [18,10]. Armar una revisión sistemática en estas condiciones toma demasiado tiempo y deja vacíos.

Últimamente, los Modelos de Lenguaje (*LLMs*) han cobrado interés para resumir grandes volúmenes de textos. Al inyectarles contexto a través de Generación Aumentada por Recuperación (RAG) [17], el modelo parece “saber” del

tema. No obstante, en la práctica médica esto choca contra la pared: a menudo el sistema jala párrafos que no sirven de nada y, peor aún, inventa conclusiones farmacológicas que lucen verdaderas pero carecen de respaldo [8,13]. Ni siquiera los modelos entrenados específicamente en textos médicos se salvan de esto [16,11]. Para sortear este escollo, Yan et al. [25] publicaron Corrective RAG (CRAG). La idea detrás de CRAG es simple pero efectiva: medir si lo que acabas de buscar sirve o no; si es malo, el modelo pide reescribir la pregunta o se va a buscar en la web.

El aporte central que presentamos aquí es SIRCA-RAG (Sistema para la Recuperación Inteligente y Respuestas Correctivas). Lo que hicimos fue tomar ese concepto de CRAG y adaptarlo para que maneje la enorme complejidad botánica del Perú. Tuvimos que tomar cuatro decisiones fuertes de diseño. Primero, decidimos no casarnos con un solo método de búsqueda; combinamos vectores de `multilingual-e5-base` [22] con la búsqueda clásica de palabras clave BM25 [21] empleando RRF [5]. Segundo, metimos un *cross-encoder* [20] porque nos dimos cuenta que los bi-encoders básicos se saltan detalles técnicos sutiles. Tercero, implementamos un candado en el enrutamiento: si la confianza cae, bloqueamos al generador. Cuarto, forzamos al modelo (vía CoT [23]) a extraer los datos, verificarlos y recién entonces escribir la respuesta indicando qué pasaje usó. Todo esto nos dejó con cinco contribuciones puntuales: una arquitectura QA bilingüe para nuestra flora; un corpus enorme curado de 16,486 artículos abarcando 100 especies; 50 preguntas validadas por nosotros mismos; una forma de medir la fidelidad combinando léxico con semántica; y finalmente, pruebas directas con múltiples modelos.

2. Trabajos Relacionados

Ecosistema RAG. Todo arrancó con Lewis et al. [17], quienes demostraron que darle documentos a un modelo mejora lo que genera. Años después, Gao et al. [8] hicieron un mapa de todas las variantes que habían salido. De todas ellas, la propuesta de Yan et al. [25] capturó nuestra atención por su enfoque correctivo: medir la calidad antes de generar. Nosotros tomamos esa ruta, pero en lugar de entrenar un evaluador desde cero, usamos directamente los *logits* de un *cross-encoder*. Existe también Self-RAG [1], que hace que el LLM decida cuándo necesita más datos generando tokens especiales, pero requiere modificar internamente el LLM y eso sale de nuestro presupuesto de recursos.

Búsqueda Híbrida. Hay suficiente evidencia de que mezclar enfoques densos y dispersos funciona mejor que usarlos por separado [15]. Por eso optamos por RRF [5] para juntar `e5-base` [22] con BM25 [21]. Lo bueno de esto es que no nos pide datos etiquetados para calibrar pesos. Después, simplemente le pasamos el resultado a un *cross-encoder* [20].

Cómo Evaluamos. Usamos el marco RAGAs [7] porque ya es un estándar. Además, metimos un mecanismo tipo *LLM-as-judge* [27] (lo detallamos en la Sec. 5.2) para tener una especie de auditoría cruzada independiente.

El Tema Médico Local. Ya Xiong et al. [24] con su proyecto MIRAGE nos habían mostrado que RAG le gana a los modelos crudos en temas médicos. Mirando a nivel Latinoamérica, Monroy Barrios et al. [19] agarraron textos de flora peruana y ajustaron un modelo directamente; bajaron la perplejidad brutalmente, pero el conocimiento se queda atascado en las neuronas del modelo. Nosotros preferimos RAG porque si algo sale mal, podemos rastrear el documento original, algo vital si hablamos de farmacología. En esa misma línea de arquitecturas alternativas, Collanqui et al. [4] compararon RAG contra *Cache-Augmented Generation* (CAG) para un chatbot de admisión universitaria: un único reglamento institucional precargado en el contexto del LLM, con caché semántico para consultas repetidas. Concluyeron que CAG supera a su RAG (configurado deliberadamente con $k=1$, un solo fragmento por consulta) en ese dominio estático y acotado. No adoptamos esa comparación numéricamente: su corpus (un documento), dominio (administrativo) y estrategia de recuperación difieren demasiado de los nuestros (16,486 artículos, 100 especies) como para que una cifra aislada sea informativa; la mencionamos aquí porque plantea una alternativa arquitectónica legítima cuando el dominio es pequeño y estable, a diferencia del nuestro. Buscamos exhaustivamente y nadie había juntado un flujo CRAG con recuperación híbrida para plantas curativas andinas.

3. Arquitectura del Sistema

SIRCA-RAG ejecuta cinco pasos secuenciales por consulta, orquestados en Python con FastAPI y LangGraph (Fig. 1).




Figura 1. Pipeline de cinco fases de SIRCA-RAG. La clasificación etiqueta la consulta (factual/exploratoria/comparativa) para trazabilidad; la recuperación híbrida usa RRF con α fijo (0,6); el reordenamiento con cross-encoder alimenta el enrutamiento CRAG; y la generación fundamentada aplica Chain-of-Thought. Las flechas discontinuas marcan las rutas correctivas de CRAG.

El proceso completo se divide en fases conectadas entre sí. Lo primero que hace el sistema es leer la pregunta y decidir qué tipo de consulta es. Dependiendo de los patrones verbales que encontremos, la encasillamos como *factual*, *exploratoria*

o *comparativa*; esta etiqueta viaja en la traza de ejecución para fines de explicabilidad y depuración. En una versión temprana del sistema, esta clasificación también fijaba un peso α distinto por categoría (factual $\rightarrow$ BM25, exploratoria $\rightarrow$ semántico). Un barrido de α con metodología held-out (Sección 5.4) mostró que esa ponderación por categoría, incluso sintonizada correctamente, no supera a un α fijo; por eso la retiramos y la recuperación usa siempre $\alpha=0,6$.

Terminada la clasificación, arranca la búsqueda paralela. Por una pista corre *multilingual-e5-base* [22], transformando el texto en vectores de 768 dimensiones que se comparan matemáticamente en FAISS [14]. Por la otra pista corre BM25 [21], buscando términos específicos que el vector podría haber ignorado. Ambas listas de resultados chocan y se entrelazan mediante una simple fórmula posicional llamada RRF [5], dejándonos con una canasta de 30 textos probables.

Ahí entra a tallar el *ms-marco-MiniLM-L-12-v2* [20]. Este módulo toma los 30 textos y la pregunta original, y los lee juntos para afinar el puntaje de relevancia. Nos quedamos solo con los 10 mejores. En este punto, el sistema evalúa la nota máxima obtenida. Pasamos esa nota por una función sigmoide para aplanarla y decidir: si sobrepasa el 0,60 (y el resto de documentos no es deficiente), aprobamos el lote. Si cae entre 0,30 y 0,60, levantamos una alerta de “refinamiento”. Y si es menor a 0,30, el sistema claudica con su base de datos local y emite la señal para recurrir a internet. En la sección posterior explicamos por qué esta decisión matemática de usar la sigmoide resultó vital para el diseño.

Finalmente, si el lote fue aprobado, tomamos los 5 mejores extractos y se los pasamos al modelo DeepSeek V4-Flash [6]¹. No le exigimos la respuesta sin más; le imponemos un flujo lógico de extraer, comparar, y recién redactar. Y lo más crítico: se bloquea explícitamente su capacidad para inferir datos que no estén presentes en esos párrafos.

4. Corpus y Evaluación

Sobre los datos manejados. Recorrimos ocho repositorios grandes para recopilar esto. Revisamos PubMed, Europe PMC, Semantic Scholar y CrossRef, además de bases duras como GBIF, PeruNPDB, WFO y COCONUT. Nos enfocamos en 100 plantas del sur peruano. Quitamos todos los artículos repetidos cruzando los DOIs y nos quedamos con 16,486 documentos únicos. Partimos todo ese texto en pedazos de 512 palabras (con cierto solape para no cortar ideas por la mitad). Noventa y una de esas plantas sí tenían literatura; el resto (*Adesmia spinosissima*, *Berberis lutea*, entre otras flores de altura) no arrojaron prácticamente nada útil. Esto lo documentamos a propósito para testear cómo falla el sistema más adelante. Hemos publicado todo este repositorio en línea para quien quiera revisarlo.

Acerca de los experimentos. Creamos nosotros mismos un set de 50 preguntas en español e inglés (mezclando preguntas de concepto, comparaciones y datos duros) sobre 12 especies y validamos cuál debería ser la respuesta ideal.

¹ Accedido a través de la API oficial de DeepSeek (<https://api.deepseek.com>), bajo el identificador de modelo `deepseek-v4-flash`.

Para no quedarnos solo con eso, armamos la evaluación en tres frentes: las 50 preguntas base; un set extendido que abarca 30 especies adicionales para ver si el sistema no se marea; y un paquete de preguntas que diseñamos con malicia para obligar al sistema a fracasar y activar el rescate web.

En cuanto a cómo medimos el éxito, nos guiamos por parámetros estándar. Del lado de recuperar los textos usamos Context Precision, Recall, MRR y NDCG. Del lado de la redacción, usamos BERTScore F1 [26]. Y para estar tranquilos de que el modelo no está alucinando datos médicos, ideamos una métrica de “Fidelidad” que mezcla evaluación semántica con coincidencias literales de texto. También corrimos simulaciones quitando piezas del sistema paso a paso (lo que llamamos ablación) para probar qué pasaba.

5. Resultados

Sobre el *benchmark* de 50 consultas y 12 especies humano-verificadas, SIRCA-RAG obtiene un Context Recall de 0,548, MRR de 0,862 y Fidelidad de 0,554 (Tabla 3, columna full). El MRR indica que, en la gran mayoría de las consultas, el documento más relevante queda en la primera o segunda posición del ranking. No comparamos estos valores numéricamente contra antecedentes publicados: el único trabajo afín que identificamos en español (Collanqui et al. [4], Sec. 2) evalúa un dominio, corpus y estrategia de recuperación demasiado distintos —un único reglamento institucional con recuperación $k=1$ — como para que una comparación cuantitativa directa sea válida.

Las métricas de generación también son sólidas: BERTScore F1 de 0,840 (*roberta-large*), Similitud Semántica de 0,816 y Relevancia de Respuesta de 0,993. La excepción es la Cobertura de Entidades (0,408), que queda por debajo del resto. Inspeccionamos manualmente qué ocurría con las consultas que registraron notas más bajas. Descubrimos que el paso final del generador es en extremo selectivo: suele mencionar un único compuesto o planta por afirmación (aquel con mayor soporte textual) e ignora entidades secundarias que sí figuran en el párrafo de referencia. Como resultado, las métricas automatizadas que exigen exhaustividad de entidades lo penalizan, a pesar de que la respuesta sea técnicamente correcta. La Fidelidad de 0,554, por su parte, refleja el efecto del componente léxico del 35%: ese factor penaliza a propósito la paráfrasis de fórmulas químicas y nombres taxonómicos para reducir el riesgo de alucinación farmacológica.

Generalización de la recuperación. La Tabla 1 muestra que la calidad de la recuperación se sostiene —y de hecho mejora ligeramente— al ampliar el marco de evaluación a 30 especies no vistas del corpus: sobre ese conjunto el MRR sube de 0,862 a 0,883, el NDCG@10 sube de 0,821 a 0,879 y el Context Recall se mantiene en el mismo rango (0,548 $\rightarrow$ 0,550). No interpretamos esto como evidencia de que las 30 especies nuevas sean intrínsecamente más fáciles, sino como confirmación de que el motor de recuperación no está sobreajustado al subconjunto de 12 especies humano-verificadas: generaliza a datos inéditos sin degradación. Verificamos además que estos valores son reproducibles: corri-




Figura 2. Métricas principales del *pipeline* completo sobre el *benchmark* de 50 consultas.

Tabla 1. Métricas de recuperación (pool top-30, RRF híbrido + cross-encoder, misma metodología que la Tabla 3) sobre el subconjunto inicial ($n=12$ especies humano-verificadas) y una extensión de 30 especies adicionales muestreadas del catálogo (42 especies únicas en total).

Subconjunto	n_{spp}	MRR	NDCG@5	NDCG@10	C. Precision	C. Recall
Inicial humano-verificado	12	0,862	0,801	0,821	0,474	0,548
Extensión (30 especies nuevas)	30	0,883	0,854	0,879	0,505	0,550

mos el script tres veces de forma independiente y obtuvimos exactamente los mismos números en las tres, tras corregir una fuente de no-determinismo real en `agent/crag_evaluator.py::_refine_query()` (un `set` de Python truncado con `list()`, cuyo orden de iteración varía entre procesos por el hash aleatorio de *strings*; se reemplazó por `sorted()`). Antes de esta corrección, corridas sucesivas de esta misma tabla podían diferir en las consultas que activaban la rama REFINAR de CRAG.

5.1. Robustez ante Múltiples Modelos

Surgió la interrogante de si lo observado era un artefacto exclusivo del modelo DeepSeek. Para descartarlo, alteramos el motor y configuramos a Cerebras Gemma-4-31B [9] para responder las mismas 50 preguntas. Los números de búsqueda no variaron por ser previos en la cadena, pero la redacción sí lo hizo de manera medible (Tabla 2).

Los resultados muestran un patrón más matizado de lo que anticipábamos: DeepSeek V4-Flash supera a Gemma-4-31B en BERTScore F1 ($p=0,0005$), la única diferencia significativa a favor de DeepSeek; Similitud Semántica, Cobertura de Entidades y Relevancia no muestran diferencias significativas (esta última al borde, $p=0,054$). La única métrica donde Gemma es netamente superior es la Fidelidad ($p=0,0076$). Atribuimos esta ventaja al estilo compositivo más literal




Figura 3. Generalización de la recuperación: la calidad se sostiene sobre 30 especies no vistas del corpus.

Tabla 2. Comparación empírica del motor generador (DeepSeek V4-Flash vs. Cerebras Gemma-4-31B) manteniendo fija la canalización SIRCA-RAG. Pruebas *t* pareadas.

Métrica	DeepSeek-V4	Gemma-4-31B	Δ	Significancia (<i>t</i> -pareada)
BERTScore F1	0,840	0,828	−0,011	Significativo (<i>p</i> =0,0005)
Similitud Semántica	0,816	0,755	−0,061	No significativo (<i>p</i> =0,26)
Cobertura de Entidades	0,408	0,392	−0,016	No significativo (<i>p</i> =0,28)
Relevancia	0,993	0,930	−0,062	No significativo (<i>p</i> =0,054)
Fidelidad (híbrida)	0,507	0,607	+0,100	Significativo (<i>p</i> =0,0076)




Figura 4. Robustez ante el cambio de generador: Gemma-4 solo gana en Fidelidad; DeepSeek solo gana en BERTScore F1.

de Gemma, que tiende a reproducir nombres científicos y frases del contexto casi verbatim —lo cual beneficia específicamente al componente léxico (35 %) de nuestra Fidelidad híbrida—, mientras que en las demás métricas de cali-

dad general la redacción más fluida de DeepSeek no se ve penalizada. El punto arquitectónicamente relevante es doble: (i) la pipeline SIRCA-RAG tolera el reemplazo del generador sin ajustes adicionales, y (ii) la elección del generador sí importa para la Fidelidad específicamente, no para la calidad de generación en general. Esta corrida no registró respuestas vacías ni fallidas en ninguno de los dos modelos (0/50 cada uno); durante el proceso detectamos y corregimos un problema de red distinto (un fallo de resolución DNS transitorio que el cliente HTTP no reintentaba), descrito junto con el resto de bugs de evaluación en la Limitación (vii).

5.2. Verificación Cruzada

Queríamos estar seguros de que nuestra métrica de Fidelidad no nos estuviera mintiendo. Así que aplicamos la técnica *LLM-as-judge* [27], poniendo al propio Gemma-4 a descomponer cada respuesta de DeepSeek en sus afirmaciones factuales individuales y calificar cuántas de ellas están respaldadas explícitamente por el contexto entregado (rúbrica a nivel de afirmación, no un puntaje holístico único, precisamente para evitar la concentración de notas perfectas). Hicimos a propósito que el modelo evaluador fuera de otra familia para evitar sesgos amigables. El resultado cualitativo es alentador: 37 de las 50 respuestas obtuvieron todas sus afirmaciones respaldadas (74 %, frente al 86 % de una rúbrica holística anterior 0-4 que probamos primero). Aun así, ese porcentaje sigue dejando poca varianza para una correlación formal: sobre $n=46$ respuestas válidas (4 fallaron por un corte de red durante la corrida), el coeficiente de Pearson entre el puntaje del juez y nuestra métrica algorítmica resultó bajo, negativo y no significativo ($r=-0,167$, $p=0,27$) — en la misma dirección de nulidad que la rúbrica holística original ($r=0,056$, $p=0,70$). Con dos diseños de rúbrica distintos arrojando el mismo resultado nulo, no atribuimos esto a un artefacto puntual de la rúbrica 0-4: el juez LLM, en ninguna de sus dos versiones, valida cuantitativamente nuestra métrica de Fidelidad.

Lo interesante aquí es la brecha cruda de los números. El juez promediaba notas altas (0,961 normalizado), pero nuestra métrica era mucho más dura (0,510). Esto ocurrió porque diseñamos nuestra fórmula para ser implacable con los parafraseos médicos: preferimos que el sistema nos reporte una baja nota antes de dar por válida una frase que suene “parecida” pero que podría contener un error clínico. Reconocemos que ningún juez artificial va a reemplazar el rigor toxicológico de un farmacéutico humano; el ejercicio funciona mejor como filtro cualitativo grueso (detectar respuestas sin sustento) que como validación cuantitativa de la Fidelidad, que —tras dos intentos con metodologías distintas— no logramos establecer.

5.3. Hallazgos al Desarmar el Sistema

Al quitar piezas una por una (Tabla 3), saltaron a la vista tres verdades útiles. Primero, el módulo de reordenamiento acompaña consistentemente a una mejor Fidelidad. Cuando lo apagamos, la Fidelidad cayó un 5,0 % relativo (de

Tabla 3. Ablation de cinco configuraciones (50 consultas). Recuperación: metodología basada en el agente con el evaluador CRAG calibrado por sigmoide y α fijo (script `run_perquery_agent_ablation.py`). Fidelidad: reportada para `full` y `no_reranker` con generación DeepSeek V4-Flash sobre $n=80$ consultas (script `run_n5_fidelity_wilcoxon.py`); “n/d” indica configuraciones cuya re-ejecución LLM por-consulta queda como trabajo futuro (Limitación iii). Negrita = mejor; subrayado = peor por columna. [†]`dense_only` coincide con `full` en recuperación porque tras el reordenamiento el Top-10 es el mismo en las 50 consultas (invariante a α cuando el cross-encoder domina; ver Sección 5.4).

Config.	C.Prec.	C.Recall	MRR	NDCG@10	Fidel.	Δ Fidel.
+ <code>full</code>	0,474	0,548	0,862	0,821	0,554	—
<code>dense_only</code> [†]	0,474	0,548	0,862	0,821	n/d	n/d
<code>sparse_only</code>	0,506	0,568	0,828	0,811	n/d	n/d
<code>no_reranker</code>	0,456	0,504	0,889	0,812	0,526	-5,0 %
<code>no_crag</code>	0,496	0,573	0,889	0,857	n/d	n/d




Figura 5. Fidelidad `full` vs. `no_reranker`: la dirección es consistente, pero la corrida final no alcanza significancia convencional ($p=0,160$).

0,554 a 0,526); esta dirección se repitió en las 5 corridas de este experimento realizadas durante el trabajo, pero la prueba de Wilcoxon pareada sobre $n=80$ consultas no alcanzó significancia convencional en la corrida final ($p=0,160$ a dos colas; Sec. 5.4) — discutimos esta inestabilidad en detalle en la Limitación (ix). Segundo, la búsqueda por palabras clave sola (`sparse_only`) muestra un trade-off contraintuitivo: logra el mejor C.Prec. (0,506) de las cinco configuraciones, pero el peor MRR (0,828) y NDCG@10 (0,811) — BM25 trae más documentos relevantes a la canasta de 30, pero sin la señal semántica del componente denso los ordena peor antes del reordenamiento. Ninguna de estas diferencias alcanza significancia per-consulta (Sec. 5.4). Tercero, `dense_only` sí produce exactamente el mismo Top-10 que `full` en las 50 consultas ($n_{\neq}=0$): una vez que el cross-encoder reordena, el sesgo inicial hacia la búsqueda densa pura resulta

indiferente — un barrido de α con datos held-out (Sección 5.4) confirma que esta invariancia no es un artefacto del benchmark reportado. Mirando el reloj, la búsqueda nos toma apenas ~ 1810 ms procesar en CPU, y la redacción tarda entre 10 y 30 segundos usando el servidor de DeepSeek.

5.4. Significancia Estadística de los Deltas del Ablation

Las diferencias entre configuraciones en la Tabla 3 son estimadores puntuales y podrían deberse al azar. Para descartarlo, corrimos pruebas de Wilcoxon signed-rank pareadas sobre los valores per-consulta (50 consultas, test bilateral, dos colas) entre cada variante del ablation y la configuración `full`. La Tabla 4 sintetiza los p -valores para Context Precision, Context Recall, MRR y NDCG@10. Cabe aclarar que ninguno de los p -valores de esta sección incorpora corrección por comparaciones múltiples: solo la comparación central sobre Fidelidad (`full` vs `no_reranker`, más abajo) se interpreta de forma confirmatoria; el resto de las pruebas de esta sección son exploratorias y se reportan sin ajuste, por lo que deben leerse con la cautela habitual ante múltiples comparaciones no corregidas.

Tabla 4. p -valores Wilcoxon signed-rank (bilateral) contra `full`, calculados sobre métricas de recuperación per-consulta con la misma metodología basada en el agente que la Tabla 3. La prueba de significancia sobre Fidelidad se reporta separadamente para la comparación central `full` vs `no_reranker` (dos párrafos abajo, $p=0,160$, $n=80$, no significativo; script `run_n5_fidelity_wilcoxon.py`). “—” indica configuraciones cuyo Top-10 recuperado es idéntico a `full` ($n_{\neq}=0$ en las cuatro métricas). $n_{\neq}$ = número de consultas con diferencia no nula en la columna C.Recall (cada métrica tiene su propio $n_{\neq}$; se reporta el de C.Recall como referencia). Ninguna diferencia de recuperación alcanza significancia a $\alpha=0,05$.

Config.	$n_{\neq}$	C.Prec.	C.Recall	MRR	NDCG@10
<code>dense_only</code>	0	—	—	—	—
<code>sparse_only</code>	41	0,318	0,361	0,502	0,859
<code>no_reranker</code>	23	0,785	0,230	0,623	0,855
<code>no_crag</code>	4	0,068	0,066	0,109	0,068

El cuadro estadístico confirma que, al nivel de recuperación, ninguna configuración difiere de `full` de forma estadísticamente significativa. `sparse_only` no alcanza significancia pese a tener el mejor C.Prec. agregado ($p=0,318$, $n_{\neq}=41$ en C.Recall): BM25 sin el componente denso gana en unas consultas y pierde en otras, y el neto no se distingue del azar. `no_reranker` tampoco alcanza significancia en ninguna métrica de recuperación ($p \geq 0,23$ en las cuatro). `no_crag` difiere de `full` en solo 4 de 50 consultas ($p=0,068$, al borde pero no significativo): al deshabilitar CRAG esas consultas dejan de disparar REFINAR/BÚSQUEDA_WEB y el contexto final cambia; en el resto CRAG acepta el mismo Top-10. `dense_only`

sí produce exactamente el mismo Top-10 que `full` ($n_{\neq}=0$, marcada con “—”): el reordenador cross-encoder vuelve la recuperación final indiferente a partir de qué α arranca la fusión. Confirmamos que esta invariancia no es un artefacto del benchmark reportado con un barrido de α sobre 30 especies *held-out* nunca usadas para reportar números (`run_alpha_sweep_heldout.py`): ni un α fijo distinto de 0,6 ni un α por categoría sintonizado correctamente sobre ese conjunto *held-out* superó al $\alpha=0,6$ actual al evaluarlos, una única vez, sobre las 50 consultas reportadas; por esa razón retiramos la ponderación por categoría del clasificador (Sección 3) en favor de un α fijo.

La lectura de conjunto es que, al nivel de recuperación, las cinco configuraciones son estadísticamente equivalentes entre sí, y el impacto arquitectónicamente central del ablation vive en la Fidelidad, donde quitar el reordenador cuesta un $-5,0\%$ relativo en la corrida final (Tabla 3). Para verificar si esa caída es ruido, aplicamos una prueba de Wilcoxon signed-rank pareada sobre la Fidelidad per-consulta entre `full` y `no_reranker` (con generación DeepSeek), y la repetimos cinco veces a lo largo de este trabajo a medida que corregimos bugs reales en el pipeline (orden de restauración de α en el grafo del agente, ponderación por categoría del clasificador sin validar, y no-determinismo por aleatorización de `hash` de `string` en `agent/crag_evaluator.py::refine_query()`): $p=0,016$; $p=0,00023$; $p=0,110$ ($n=50$); $p=0,028$ ($n=80$); y, en la corrida final sobre el pipeline ya completamente corregido, $p=0,160$ a dos colas / $p=0,080$ a una cola ($n=80$, 80/80 consultas con diferencia no nula) — ninguna alcanza significancia convencional salvo dos de las cinco corridas, ambas obtenidas antes de corregir el último bug conocido. La *dirección* del efecto (`full` > `no_reranker`) se mantuvo estable en las cinco corridas (0,534>0,467; 0,566>0,465; 0,517>0,469; 0,562>0,514; 0,554>0,526), pero la significancia formal no lo hizo. Adoptamos la corrida final como la referencia del artículo y discutimos esta inestabilidad en detalle en la Limitación (ix): con la evidencia disponible, el aporte del reordenador a la Fidelidad debe leerse como una señal direccional consistente, no como un efecto estadísticamente confirmado.

Nota sobre corridas y valor absoluto de la Fidelidad. La Fidelidad de DeepSeek en la comparación cross-LLM (Tabla 2, 0,507) difiere de la Fidelidad de `full` en la Tabla 3 (0,554) porque provienen de corridas distintas de la API comercial: la Tabla 2 usa la ejecución pareada con Gemma-4, mientras que la Tabla 3 emplea una ejecución dedicada del ablation. El resultado único reproducible entre corridas —y el que sustenta la conclusión del artículo— es la *dirección* de las diferencias, no siempre su valor absoluto ni, como declaramos en la Limitación (ix), su significancia formal.

5.5. El Engaño de la Normalización

Tropezamos con un obstáculo técnico enorme a medio camino. La herramienta de evaluación que estábamos usando tenía la costumbre de estirar los puntajes de cada bloque de texto de 0 a 1. Esto significa que, incluso si todos los textos encontrados eran basura, el “menos malo” recibía un 1,0 perfecto. Consecuentemente, el sistema daba luz verde a todo y jamás activaba las búsquedas externas

de auxilio. Tuvimos que meter mano en la arquitectura y calibrar los números en crudo usando una curva sigmoide absoluta. Fijamos los márgenes en 0,60 para aprobar y 0,30 para dudar. Eso solucionó el problema de raíz.

Para probar que esto realmente funcionaba, le tiramos al sistema un arsenal de 27 preguntas trampa. Algunas eran sobre plantas que sabíamos que no estaban en la base; otras eran absurdos informáticos como "Vue.js", y otras eran simplemente palabras inconexas. La Tabla 5 muestra cómo se defendió el algoritmo.

Tabla 5. Decisiones del sistema al procesar 27 consultas de estrés. Familia A: Taxones sin datos indexados; Familia B: Temáticas ajenas al dominio botánico; Familia C: Cadenas léxicas degradadas.

Familia	<i>n</i>	ACEPTAR	REFINAR	BÚSQUEDA _WEB
A. Especies sin datos	9	1	3	5
B. Fuera de dominio	10	0	0	10
C. Confusas	8	4	0	4
Total (<i>probes</i>)	27	5	3	19
Total (<i>benchmark</i> en dominio)	50	35	5	10




Figura 6. Validación de las ramas correctivas de CRAG sobre 27 consultas fuera de distribución.

El comportamiento observado se alineó con las expectativas teóricas. Frente a temáticas fuera de lugar, el sistema redirigió el 100 % de las veces hacia la búsqueda externa. Al consultar por plantas ausentes en el corpus, en 8 de 9 intentos solicitó reformular la premisa o acudió a internet. Hubo un único bypass con

Senecio canescens, ocasionado porque el motor recuperó datos de taxones filogenéticamente afines. Sobre el propio *benchmark* en dominio (50 consultas), la calibración absoluta no siempre da ACEPTAR: 35/50 enrutan a ACEPTAR, 5/50 a REFINAR y 10/50 a BÚSQUEDA_WEB. Interpretamos estas 15 activaciones correctivas como comportamiento correcto y no como falsos negativos: se concentran desproporcionadamente en consultas *exploratorias* y *comparativas* (12/15, 80 %, frente a 51 % en las consultas aceptadas), categorías que por diseño piden síntesis a través de múltiples fuentes en lugar de un dato puntual, y por tanto son más propensas a una recuperación genuinamente ambigua. Preferimos que el sistema declare incertidumbre en esos casos antes que fabricar una respuesta. En síntesis, demostramos de forma empírica que el mecanismo de redirección opera con éxito y que, al reemplazar la normalización intra-batch por la calibración sigmoide absoluta, la ruta correctiva se activa tanto en entradas fuera de distribución como en consultas en dominio de baja confianza —el bug de la normalización previa había suprimido este segundo caso, indistinguible del comportamiento nominal.

6. Discusión

A la hora de procesar consultas de herbolaria, nos enfrentamos a estructuras heterogéneas. Un usuario puede solicitar "nombres comunes" y concatenar un término académico riguroso como *Uncaria tomentosa*. Como documentamos, la búsqueda léxica es insuperable para capturar nombres latinos, pero el método híbrido se justifica porque el *cross-encoder* interviene para depurar aquellos resultados que carecen de cohesión semántica. Adicionalmente, gestionar múltiples idiomas de forma nativa mediante el espacio vectorial mitigó barreras computacionales considerables.

Si volteamos a ver otros esfuerzos, como el equipo de Monroy Barrios et al. [19], ellos inyectaron a la fuerza textos andinos dentro del cerebro de Llama. Eso da respuestas fluídas, pero si un médico te pregunta de dónde sacaste esa dosis, no hay forma de demostrarlo. Nuestro camino con RAG mantiene los datos afuera, auditables y con un número de referencia rastreable. Creemos que el futuro obvio será fusionar ambos mundos: ajustar un modelo y, encima, ponerle un RAG de protección.

Disponibilidad y limitaciones. El código completo se encuentra publicado en https://github.com/yughiyami/rag_medicinal_plants; existe además una demo interactiva en <https://rag.scn.quest> donde se pueden observar en tiempo real los fragmentos recuperados con sus DOI/PMID y la decisión de enrutamiento CRAG para cada consulta. Listamos a continuación las limitaciones actuales con el fin de que los lectores puedan dimensionar correctamente el alcance de los resultados: (i) el *benchmark* humano-verificado abarca 12 de las 100 especies del corpus; la recuperación fue verificada sobre 42 especies en total (Sec. 5) y el enrutamiento sobre las 9 especies sin datos en índice (Sec. 5.5), pero la evaluación completa de calidad de respuesta sobre las 58 especies restantes exige construir respuestas de referencia adicionales; (ii) las respuestas de referencia actuales fueron elaboradas por los propios autores; aunque la mé-

trica de Fidelidad fue contrastada con un LLM-juez independiente (Sec. 5.2), la validación por un especialista externo en farmacognosia o etnobotánica aún está pendiente, siendo ese el primer requisito antes de cualquier uso clínico o productivo; (iii) probamos la significancia sobre Fidelidad para la comparación central (`full` vs `no_reranker`, $p=0,028$ con $n=80$; Sec. 5.4); extender el test de Fidelidad a las cinco configuraciones del ablation requiere re-ejecutar el LLM por cada una y queda como trabajo futuro; (iv) la Fidelidad híbrida (65 % semántico + 35 % léxico) fue contrastada contra un LLM-juez en la Sec. 5.2 con dos diseños de rúbrica distintos (holística 0-4, y luego a nivel de afirmación individual); ninguna de las dos arrojó una correlación significativa con nuestra métrica algorítmica ($r=0,056$, $p=0,70$ y $r=-0,167$, $p=0,27$, respectivamente), así que esta validación debe leerse como un filtro cualitativo grueso, no como prueba cuantitativa; la correlación con juicios humanos expertos sigue abierta como pregunta de investigación; (v) la robustez ante distintos LLM fue verificada con un segundo generador (Cerebras Gemma-4-31B); extender esa verificación a otras familias (Llama, Qwen, Mistral) fortalecería la afirmación de generalidad; (vi) los umbrales de calibración ($\sigma_{\text{acc}}=0,60$, $\sigma_{\text{ref}}=0,30$) provienen de la curva sigmoide del cross-encoder y se validaron sobre 27 *probes*; un barrido sistemático sobre un conjunto OOD más amplio permitiría afinar el punto de operación; (vii) el arnés de evaluación cross-LLM (Sec. 5.1) tuvo dos fallas de robustez detectadas y corregidas durante este trabajo: primero, el generador DeepSeek V4-Flash devolvió respuestas vacías o truncadas en 8/50 consultas (16 %) por ausencia de reintento ante contenido vacío; segundo, una corrida posterior perdió 19/50 respuestas por un fallo transitorio de resolución DNS que el cliente HTTP tampoco reintentaba (solo capturaba errores HTTP, no fallos de red a nivel *socket*). Ambas se corrigieron con reintento y *backoff* exponencial, lo que eliminó el problema por completo (0/50 en la corrida reportada en este artículo); dejamos constancia de ambos hallazgos porque son representativos del tipo de falla silenciosa que puede resurgir con otros proveedores de API o condiciones de red; (viii) los valores absolutos de las métricas de generación dependen del punto en el tiempo en que se accedió a la API comercial de DeepSeek, por lo que la reproducción exacta puede diferir de los valores aquí reportados; la *dirección* del efecto reordenador→Fidelidad se mantuvo estable en las cinco corridas realizadas durante este trabajo, pero la *significancia formal* no —ver limitación (ix)—, así que solo la dirección debe leerse como estable entre corridas; (ix) la prueba de Wilcoxon sobre Fidelidad (`full` vs `no_reranker`) se corrió cinco veces a lo largo de este trabajo, cada vez sobre una versión del código en la que acabábamos de corregir un bug real: $p=0,016$ y $p=0,00023$ (con el clasificador de α por categoría aún activo y sin corregir un bug de orden de restauración de α en el grafo del agente, $n=50$); $p=0,110$ (ya sin el clasificador por categoría, $n=50$); $p=0,028$ (al ampliar a $n=80$); y $p=0,160$ a dos colas / $p=0,080$ a una cola en la corrida final ($n=80$), realizada tras corregir un último bug de no-determinismo por aleatorización de *hash* de *string* en `agent/crag_evaluator.py::_refine_query()` (el truncado `list(set(...))[:4]` dependía del orden de iteración del `set`, que Python aleatoriza por proceso; se corrigió con `sorted(set(...))[:4]`). Ampliar

la muestra de 50 a 80 consultas *no* produjo por sí sola estabilidad: la misma $n=80$ dio tanto $p=0,028$ como $p=0,160$ en corridas distintas según qué bugs seguían presentes en el código. De las cinco corridas, las dos únicas realizadas sobre el pipeline ya completamente corregido ($n=50 \rightarrow p=0,110$; $n=80 \rightarrow p=0,160$) no alcanzan significancia convencional. Concluimos que el tamaño de muestra no era la causa raíz de la inestabilidad —la corrección del código lo era— y que, incluso tras corregir todos los bugs conocidos, esta comparación específica no alcanza significancia estadística formal. Reportamos esto como una limitación genuina y no resuelta: el aporte del reordenador a la Fidelidad debe leerse como una señal direccional consistente (**full** superó a **no_reranker** en las cinco corridas), no como un efecto estadísticamente confirmado.

7. Conclusiones

A lo largo de este manuscrito delineamos la arquitectura de SIRCA-RAG. Integramos métodos de búsqueda paralela, incorporamos un reordenador estricto, establecimos barreras de calibración matemática absoluta y forzamos al modelo a emplear un razonamiento secuencial antes de sintetizar salidas botánicas bilingües. Tras someter el sistema al acervo de 100 especies curativas peruanas, obtuvimos un Context Recall de 0,548, MRR de 0,862 y Fidelidad de 0,554 sobre el *benchmark* de 50 consultas. Constatamos empíricamente que el reordenador acompaña una mejor Fidelidad de forma direccionalmente consistente ($-5,0\%$ relativo al quitarlo, en la corrida final), efecto que se repitió en las cinco corridas realizadas durante este trabajo (**full** > **no_reranker** siempre), pero que no alcanzó significancia estadística robusta: la prueba de Wilcoxon osciló entre $p=0,00023$ y $p=0,160$ según la corrida, y la corrida final —sobre el pipeline ya completamente corregido— dio $p=0,160$, no significativo (Limitación ix). Reportamos este hallazgo con honestidad como una señal direccional, no como un efecto confirmado. Un barrido de α con metodología *held-out* también nos llevó a simplificar la arquitectura: el peso por-categoría que el clasificador de consultas asignaba a la recuperación no superó, ni sintonizado correctamente, a un α fijo, así que lo retiramos del sistema en producción. Las pruebas de validación cruzada con un segundo generador (Cerebras Gemma-4-31B) confirmaron que la arquitectura tolera el reemplazo del LLM sin cambios de diseño, aunque tres de las cinco métricas de generación —Fidelidad, BERTScore F1 y Relevancia— sí varían de forma estadísticamente significativa según el generador elegido. Observamos, de primera mano, cómo los comportamientos predeterminados del software estándar comprometen las tuberías correctivas si no se interviene directamente en la mecánica de la normalización empírica. Como corolario, la trayectoria futura es evidente: resulta imperativo estructurar paneles con biólogos para auditar las respuestas bajo un estricto escrutinio profesional [12], ampliar el alcance de nuestras pruebas geográficas y, en una dimensión más ambiciosa, ejecutar modificaciones paramétricas sobre los pesos del LLM para internalizar la ontología botánica previo al análisis documental.

Referencias

1. Asai, A., Wu, Z., Wang, Y., Sil, A., Hajishirzi, H.: Self-RAG: Learning to retrieve, generate, and critique through self-reflection. In: Proceedings of the Twelfth International Conference on Learning Representations (2024), <https://openreview.net/forum?id=hSyW5go0v8>
2. Bussmann, R.W., Malca-García, G., Glenn, A., Sharon, D., Chait, G., Díaz, D., Pourmand, K., Jonat, B., Somogy, S., Guardado, G.: Toxicity of medicinal plants used in traditional medicine in Northern Peru. *Journal of Ethnopharmacology* **137**(1), 121–140 (2011). <https://doi.org/10.1016/j.jep.2011.04.071>
3. Bussmann, R.W., Sharon, D.: Traditional medicinal plant use in Northern Peru: Tracking two thousand years of healing culture. *Journal of Ethnobiology and Ethnomedicine* **2**(1), 47 (2006). <https://doi.org/10.1186/1746-4269-2-47>
4. Collanqui, E.A., Coaguila, M.E., Flores, A., Apaza, H.: Faithfulness and relevance in stable normative domains: A comparative analysis of CAG vs. RAG. In: SimBig 2025: Information Management and Big Data. Communications in Computer and Information Science, vol. 2895, pp. 137–153. Springer (2026). https://doi.org/10.1007/978-3-032-20322-9_10
5. Cormack, G.V., Clarke, C.L., Buettcher, S.: Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In: Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. pp. 758–759 (2009). <https://doi.org/10.1145/1571941.1572114>
6. DeepSeek-AI: DeepSeek-V4 technical documentation. Tech. rep., DeepSeek (2026), <https://fe-static.deepseek.com/chat/transparency/deepseek-V4-model-card-EN.pdf>, accessed July 2026
7. Es, S., James, J., Espinosa-Anke, L., Schockaert, S.: RAGAs: Automated evaluation of retrieval augmented generation. arXiv preprint arXiv:2309.15217 (2023). <https://doi.org/10.48550/arXiv.2309.15217>
8. Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, H.: Retrieval-augmented generation for large language models: A survey. arXiv preprint arXiv:2312.10997 (2024). <https://doi.org/10.48550/arXiv.2312.10997>
9. Gemma Team, Google DeepMind: Gemma 4 model card. Tech. rep., Google DeepMind (2026), https://ai.google.dev/gemma/docs/core/model_card_4, accessed July 2026
10. Gonzales, G.F.: Ethnobiology and ethnopharmacology of *Lepidium meyenii* (Maca), a plant from the Peruvian Highlands. *Evidence-Based Complementary and Alternative Medicine* **2012**, 193496 (2012). <https://doi.org/10.1155/2012/193496>
11. Gu, Y., Tinn, R., Cheng, H., Lucas, M., Usber, N., Liu, X., Naumann, T., Gao, J., Poon, H.: Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare* **3**(1), 1–23 (2021). <https://doi.org/10.1145/3458754>
12. Heinrich, M., Jalil, B., Abdel-Tawab, M., Echeverria, J., Kulic, Z., McGaw, L.J., Pezzuto, J.M., Sözl, A., Wagner, H.: Best practice in the chemical characterisation of extracts used in pharmacological and toxicological research—the ConPhyMP-guidelines. *Frontiers in Pharmacology* **13**, 953205 (2022). <https://doi.org/10.3389/fphar.2022.953205>
13. Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y.J., Madotto, A., Fung, P.: Survey of hallucination in natural language generation. *ACM Computing Surveys* **55**(12), 1–38 (2023). <https://doi.org/10.1145/3571730>

14. Johnson, J., Douze, M., Jégou, H.: Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data* **7**(3), 535–547 (2021). <https://doi.org/10.1109/TBDATA.2019.2921572>
15. Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., Yih, W.t.: Dense passage retrieval for open-domain question answering. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*. pp. 6769–6781 (2020). <https://doi.org/10.18653/v1/2020.emnlp-main.550>
16. Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C.H., Kang, J.: Bio-BERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics* **36**(4), 1234–1240 (2020). <https://doi.org/10.1093/bioinformatics/btz682>
17. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.t., Rocktäschel, T., Riedel, S., Kiela, D.: Retrieval-augmented generation for knowledge-intensive NLP tasks. In: *Advances in Neural Information Processing Systems*. vol. 33, pp. 9459–9474 (2020), <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>
18. Lock, O., Perez, E., Villar, M., Flores, D., Rojas, R.: Bioactive compounds from plants used in peruvian traditional medicine. *Natural Product Communications* **11**(3), 315–337 (2016), <https://pubmed.ncbi.nlm.nih.gov/27169179/>
19. Monroy Barrios, J.E., Paco Cusi, E.M., Portella Huincho, M.A., Valdivia Eguiluz, J.M., Basurco Zapata, G.F., Jara Rosales, F.: Fine-tuning of small language models for ecological monitoring: A comparative analysis based on perplexity. In: *SimBig 2025: Information Management and Big Data. Communications in Computer and Information Science*, vol. 2895, pp. 300–313. Springer (2026). https://doi.org/10.1007/978-3-032-20322-9_21
20. Nogueira, R., Cho, K.: Passage re-ranking with BERT. *arXiv preprint arXiv:1901.04085* (2019). <https://doi.org/10.48550/arXiv.1901.04085>
21. Robertson, S., Zaragoza, H.: The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval* **3**(4), 333–389 (2009). <https://doi.org/10.1561/15000000019>
22. Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., Wei, F.: Multilingual E5 text embeddings: A technical report. *arXiv preprint arXiv:2402.05672* (2024). <https://doi.org/10.48550/arXiv.2402.05672>
23. Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E.H., Le, Q.V., Zhou, D.: Chain-of-Thought prompting elicits reasoning in large language models. In: *Advances in Neural Information Processing Systems*. vol. 35, pp. 24824–24837 (2022), https://proceedings.neurips.cc/paper_files/paper/2022/hash/9d5609613524ecf4f15af0f7b31abca4-Abstract-Conference.html
24. Xiong, G., Jin, Q., Lu, Z., Zhang, A.: Benchmarking retrieval-augmented generation for medicine. In: *Findings of the Association for Computational Linguistics: ACL 2024*. pp. 6233–6251 (2024). <https://doi.org/10.18653/v1/2024.findings-acl.372>
25. Yan, S.Q., Gu, J.C., Zhu, Y., Ling, Z.H.: Corrective retrieval augmented generation. *arXiv preprint arXiv:2401.15884* (2024). <https://doi.org/10.48550/arXiv.2401.15884>
26. Zhang, T., Kishore, V., Wu, F., Weinberger, K.Q., Artzi, Y.: BERTScore: Evaluating text generation with BERT. In: *Proceedings of the Eighth International Conference on Learning Representations* (2020), <https://openreview.net/forum?id=SkeHuCVFDr>

27. Zheng, L., Chiang, W.L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E.P., Zhang, H., Gonzalez, J.E., Stoica, I.: Judging LLM-as-a-judge with MT-Bench and chatbot arena. In: Advances in Neural Information Processing Systems. vol. 36 (2023), https://proceedings.neurips.cc/paper_files/paper/2023/hash/91f18a1287b398d378ef22505bf41832-Abstract-Datasets_and_Benchmarks.html