

Corrective RAG Híbrido para generación fundamentada sobre plantas medicinales Peruanas

Ower Lopez-Arela^[0009-0008-1075-4275], Daniel
Marron-Carcausto^[0009-0008-5964-0201], and Antonio
Arroyo-Paz^[0000-0003-1838-4527]

Escuela Profesional de Ingeniería de Sistemas, Universidad Nacional de San Agustín
de Arequipa, Perú
`{olopeza, dmarron, aarroyop}@unsa.edu.pe`

Resumen La vasta literatura existente sobre las plantas medicinales del Perú sufre un grave problema de fragmentación. Al estar repartida entre numerosos repositorios, extraer evidencia farmacológica real resulta costoso. Para hacer frente a esto, proponemos SIRCA-RAG (Sistema para la Recuperación Inteligente y Respuestas Correctivas), una arquitectura bilingüe diseñada para unificar dicha evidencia mediante técnicas correctivas. Nuestra solución fusiona búsquedas densas con léxicas (BM25) usando *Reciprocal Rank Fusion*, y luego aplica un reordenador cruzado (*cross-encoder*) que termina siendo vital para proteger la exactitud de las respuestas. Un enrutador tipo CRAG gestiona la calidad final. Evaluamos la herramienta en un entorno real con 16,486 artículos (cubriendo 100 especies locales), logrando una Fidelidad de 0,566 y un MRR de 0,837. En Context Recall (Cobertura de Contexto) —la única métrica que reporta el antecedente comparable— superamos su resultado en un 18,0% relativo. También demostramos empíricamente que la normalización por defecto arruina los enrutamientos; tuvimos que forzar una calibración sigmoide absoluta para que las derivaciones hacia búsqueda externa funcionaran de forma legítima.

Keywords: Retrieval-Augmented Generation (RAG) · Etnobotánica Peruana · Modelos de Lenguaje Grande (LLM) · Recuperación Híbrida · Procesamiento de Lenguaje Natural (NLP)

1. Introducción

Sabemos que el Perú posee cerca de 25,000 especies vegetales, y al menos entre 1,400 y 5,000 gozan de algún grado de evidencia farmacológica [3,2]. Sin embargo, si un investigador quiere rastrear datos específicos sobre *Uncaria tomentosa* o *Croton lechleri*, pronto se topará con el problema central: los datos no están en un solo lugar. Las publicaciones se hallan regadas por todo PubMed, así como en bases de biodiversidad locales y registros internacionales [18,10]. Armar una revisión sistemática en estas condiciones toma demasiado tiempo y deja vacíos.

Últimamente, los Modelos de Lenguaje (*LLMs*) han cobrado interés para resumir grandes volúmenes de textos. Al inyectarles contexto a través de Generación Aumentada por Recuperación (RAG) [17], el modelo parece “saber” del tema. No obstante, en la práctica médica esto choca contra la pared: a menudo el sistema jala párrafos que no sirven de nada y, peor aún, inventa conclusiones farmacológicas que lucen verdaderas pero carecen de respaldo [8,13]. Ni siquiera los modelos entrenados específicamente en textos médicos se salvan de esto [16,11]. Para sortear este escollo, Yan et al. [25] publicaron Corrective RAG (CRAG). La idea detrás de CRAG es simple pero efectiva: medir si lo que acabas de buscar sirve o no; si es malo, el modelo pide reescribir la pregunta o se va a buscar en la web.

El aporte central que presentamos aquí es SIRCA-RAG (Sistema para la Recuperación Inteligente y Respuestas Correctivas). Lo que hicimos fue tomar ese concepto de CRAG y adaptarlo para que maneje la enorme complejidad botánica del Perú. Tuvimos que tomar cuatro decisiones fuertes de diseño. Primero, decidimos no casarnos con un solo método de búsqueda; combinamos vectores de *multilingual-e5-base* [22] con la búsqueda clásica de palabras clave BM25 [21] empleando RRF [5]. Segundo, metimos un *cross-encoder* [20] porque nos dimos cuenta que los bi-encoders básicos se saltan detalles técnicos sutiles. Tercero, implementamos un candado en el enrutamiento: si la confianza cae, bloqueamos al generador. Cuarto, forzamos al modelo (vía CoT [23]) a extraer los datos, verificarlos y recién entonces escribir la respuesta indicando qué pasaje usó. Todo esto nos dejó con cinco contribuciones puntuales: una arquitectura QA bilingüe para nuestra flora; un corpus enorme curado de 16,486 artículos abarcando 100 especies; 50 preguntas validadas por nosotros mismos; una forma de medir la fidelidad combinando léxico con semántica; y finalmente, pruebas directas con múltiples modelos.

2. Trabajos Relacionados

Ecosistema RAG. Todo arrancó con Lewis et al. [17], quienes demostraron que darle documentos a un modelo mejora lo que genera. Años después, Gao et al. [8] hicieron un mapa de todas las variantes que habían salido. De todas ellas, la propuesta de Yan et al. [25] capturó nuestra atención por su enfoque correctivo: medir la calidad antes de generar. Nosotros tomamos esa ruta, pero en lugar de entrenar un evaluador desde cero, usamos directamente los *logits* de un *cross-encoder*. Existe también Self-RAG [1], que hace que el LLM decida cuándo necesita más datos generando tokens especiales, pero requiere modificar internamente el LLM y eso sale de nuestro presupuesto de recursos.

Búsqueda Híbrida. Hay suficiente evidencia de que mezclar enfoques densos y dispersos funciona mejor que usarlos por separado [15]. Por eso optamos por RRF [5] para juntar *e5-base* [22] con BM25 [21]. Lo bueno de esto es que no nos pide datos etiquetados para calibrar pesos. Después, simplemente le pasamos el resultado a un *cross-encoder* [20].

Cómo Evaluamos. Usamos el marco RAGAs [7] porque ya es un estándar. Además, metimos un mecanismo tipo *LLM-as-judge* [27] (lo detallamos en la Sec. 5.2) para tener una especie de auditoría cruzada independiente.

El Tema Médico Local. Ya Xiong et al. [24] con su proyecto MIRAGE nos habían mostrado que RAG le gana a los modelos crudos en temas médicos. Mirando a nivel Latinoamérica, Monroy Barrios et al. [19] agarraron textos de flora peruana y ajustaron un modelo directamente; bajaron la perplejidad brutalmente, pero el conocimiento se queda atascado en las neuronas del modelo. Nosotros preferimos RAG porque si algo sale mal, podemos rastrear el documento original, algo vital si hablamos de farmacología. Como referencia de rendimiento, Collanqui et al. [4] lograron un *Recall* de 0,417 con Llama 3.1 en leyes peruanas, un número que usamos para compararnos (nosotros llegamos a 0,492). Buscamos exhaustivamente y nadie había juntado un flujo CRAG con recuperación híbrida para plantas curativas andinas.

3. Arquitectura del Sistema

SIRCA-RAG ejecuta cinco pasos secuenciales por consulta, orquestados en Python con FastAPI y LangGraph (Fig. 1).




Figura 1. Pipeline de cinco fases de SIRCA-RAG. La clasificación fija α ; la recuperación híbrida usa RRF; el reordenamiento con cross-encoder alimenta el enrutamiento CRAG; y la generación fundamentada aplica Chain-of-Thought. Las flechas discontinuas marcan las rutas correctivas de CRAG.

El proceso completo se divide en fases conectadas entre sí. Lo primero que hace el sistema es leer la pregunta y decidir qué tipo de consulta es. Dependiendo de los patrones verbales que encontremos, la encasillamos como *factual*, *exploratoria* o *comparativa*. Esta clasificación no es un mero adorno; altera internamente el peso α que le damos a la búsqueda. Si nos piden un dato duro, le damos más peso a la coincidencia de palabras clave vía BM25 ($\alpha=0,3$). Si la duda es abierta, privilegiamos el lado semántico ($\alpha=0,7$).

Terminada la clasificación, arranca la búsqueda paralela. Por una pista corre *multilingual-e5-base* [22], transformando el texto en vectores de 768 dimensiones que se comparan matemáticamente en FAISS [14]. Por la otra pista corre

BM25 [21], buscando términos específicos que el vector podría haber ignorado. Ambas listas de resultados chocan y se entrelazan mediante una simple fórmula posicional llamada RRF [5], dejándonos con una canasta de 30 textos probables.

Ahí entra a tallar el `ms-marco-MiniLM-L-12-v2` [20]. Este módulo toma los 30 textos y la pregunta original, y los lee juntos para afinar el puntaje de relevancia. Nos quedamos solo con los 10 mejores. En este punto, el sistema evalúa la nota máxima obtenida. Pasamos esa nota por una función sigmoide para aplanarla y decidir: si sobrepasa el 0,60 (y el resto de documentos no es deficiente), aprobamos el lote. Si cae entre 0,30 y 0,60, levantamos una alerta de “refinamiento”. Y si es menor a 0,30, el sistema claudica con su base de datos local y emite la señal para recurrir a internet. En la sección posterior explicamos por qué esta decisión matemática de usar la sigmoide resultó vital para el diseño.

Finalmente, si el lote fue aprobado, tomamos los 5 mejores extractos y se los pasamos al modelo DeepSeek V4-Flash [6]¹. No le exigimos la respuesta sin más; le imponemos un flujo lógico de extraer, comparar, y recién redactar. Y lo más crítico: se bloquea explícitamente su capacidad para inferir datos que no estén presentes en esos párrafos.

4. Corpus y Evaluación

Sobre los datos manejados. Recorrimos ocho repositorios grandes para recopilar esto. Revisamos PubMed, Europe PMC, Semantic Scholar y CrossRef, además de bases duras como GBIF, PeruNPDB, WFO y COCONUT. Nos enfocamos en 100 plantas del sur peruano. Quitamos todos los artículos repetidos cruzando los DOIs y nos quedamos con 16,486 documentos únicos. Partimos todo ese texto en pedazos de 512 palabras (con cierto solape para no cortar ideas por la mitad). Noventa y una de esas plantas sí tenían literatura; el resto (*Adesmia spinosissima*, *Berberis lutea*, entre otras flores de altura) no arrojaron prácticamente nada útil. Esto lo documentamos a propósito para testear cómo falla el sistema más adelante. Hemos publicado todo este repositorio en línea para quien quiera revisarlo.

Acerca de los experimentos. Creamos nosotros mismos un set de 50 preguntas en español e inglés (mezclando preguntas de concepto, comparaciones y datos duros) sobre 12 especies y validamos cuál debería ser la respuesta ideal. Para no quedarnos solo con eso, armamos la evaluación en tres frentes: las 50 preguntas base; un set extendido que abarca 30 especies adicionales para ver si el sistema no se marea; y un paquete de preguntas que diseñamos con malicia para obligar al sistema a fracasar y activar el rescate web.

En cuanto a cómo medimos el éxito, nos guiamos por parámetros estándar. Del lado de recuperar los textos usamos Context Precision, Recall, MRR y NDCG. Del lado de la redacción, usamos BERTScore F1 [26]. Y para estar tranquilos de que el modelo no está alucinando datos médicos, ideamos una métrica de “Fidelidad” que mezcla evaluación semántica con coincidencias literales de

¹ Accedido a través de la API oficial de DeepSeek (<https://api.deepseek.com>), bajo el identificador de modelo `deepseek-v4-flash`.

texto. También corrimos simulaciones quitando piezas del sistema paso a paso (lo que llamamos ablación) para probar qué pasaba.

5. Resultados

La Tabla 1 muestra cómo queda SIRCA-RAG frente al sistema más próximo publicado bajo el mismo marco RAGAs para texto biomédico y normativo en español. La mejora en Context Recall (Cobertura de Contexto) es de 18,0% en términos relativos (7,5 puntos porcentuales absolutos: 0,492 frente a 0,417) por encima de Collanqui et al. [4]; conviene precisar que esta comparación cuantitativa aplica únicamente a Context Recall, pues dicho antecedente no reporta MRR ni Fidelidad (celdas “—” en la Tabla 1). El MRR de 0,837 indica que, en la gran mayoría de las consultas, el documento más relevante queda en la primera o segunda posición del ranking.

Tabla 1. Comparación contra el *baseline* publicado más cercano bajo el marco RAGAs. “—” = métrica no reportada.

Sistema	LLM	C.Recall	MRR	Fidel.
Collanqui et al. [4] (CAG)	Llama 3.1	0,417	—	—
SIRCA-RAG (nuestro)	DeepSeek V4-Flash	0,492	0,837	0,566

Las métricas de generación también son sólidas: BERTScore F1 de 0,841 (*roberta-large*), Similitud Semántica de 0,852 y Relevancia de Respuesta de 0,998. La excepción es la Cobertura de Entidades (0,402), que queda por debajo del resto. Inspeccionamos manualmente qué ocurría con las consultas que registraron notas más bajas. Descubrimos que el paso final del generador es en extremo selectivo: suele mencionar un único compuesto o planta por afirmación (aquel con mayor soporte textual) e ignora entidades secundarias que sí figuran en el párrafo de referencia. Como resultado, las métricas automatizadas que exigen exhaustividad de entidades lo penalizan, a pesar de que la respuesta sea técnicamente correcta. La Fidelidad de 0,566, por su parte, refleja el efecto del componente léxico del 35%: ese factor penaliza a propósito la paráfrasis de fórmulas químicas y nombres taxonómicos para reducir el riesgo de alucinación farmacológica.

Generalización de la recuperación. La Tabla 2 muestra que la calidad de la recuperación se sostiene —y de hecho mejora ligeramente— al ampliar el marco de evaluación a 30 especies no vistas del corpus: sobre ese conjunto el MRR sube de 0,837 a 0,870, el NDCG@10 sube de 0,750 a 0,841 y el Context Recall también mejora (0,492 → 0,535). No interpretamos esto como evidencia de que las 30 especies nuevas sean intrínsecamente más fáciles, sino como confirmación de que el motor de recuperación no está sobreajustado al subconjunto de 12 especies humano-verificadas: generaliza a datos inéditos sin degradación.

Tabla 2. Métricas de recuperación (pool top-30, RRF híbrido + cross-encoder, misma metodología que la Tabla 4) sobre el subconjunto inicial ($n=12$ especies humano-verificadas) y una extensión de 30 especies adicionales muestreadas del catálogo (42 especies únicas en total).

Subconjunto	n_{spp}	MRR	NDCG@5	NDCG@10	C. Precision	C. Recall
Inicial humano-verificado	12	0,837	0,757	0,750	0,415	0,492
Extensión (30 especies nuevas)	30	0,870	0,816	0,841	0,463	0,535

5.1. Robustez ante Múltiples Modelos

Surgió la interrogante de si lo observado era un artefacto exclusivo del modelo DeepSeek. Para descartarlo, alteramos el motor y configuramos a Cerebras Gemma-4-31B [9] para responder las mismas 50 preguntas. Los números de búsqueda no variaron por ser previos en la cadena, pero la redacción sí lo hizo de manera medible (Tabla 3).

Tabla 3. Comparación empírica del motor generador (DeepSeek V4-Flash vs. Cerebras Gemma-4-31B) manteniendo fija la canalización SIRCA-RAG. Pruebas t pareadas.

Métrica	DeepSeek-V4	Gemma-4-31B	Δ	Significancia (t -pareada)
BERTScore F1	0,841	0,830	−0,011	Significativo ($p=0,005$)
Similitud Semántica	0,852	0,789	−0,063	No significativo ($p=0,18$)
Cobertura de Entidades	0,402	0,386	−0,016	No significativo ($p=0,46$)
Relevancia	0,998	0,988	−0,010	Significativo ($p=0,042$)
Fidelidad (híbrida)	0,517	0,609	+0,092	Significativo ($p<0,001$)

Los resultados muestran un patrón más matizado de lo que anticipábamos: DeepSeek V4-Flash iguala o supera a Gemma-4-31B en cuatro de las cinco métricas de generación —incluyendo BERTScore F1 ($p=0,005$) y Relevancia ($p=0,042$), ambas significativas a favor de DeepSeek—, mientras que Similitud Semántica y Cobertura de Entidades no muestran diferencias significativas. La única métrica donde Gemma es netamente superior es la Fidelidad ($p<0,001$). Atribuimos esta única ventaja al estilo compositivo más literal de Gemma, que tiende a reproducir nombres científicos y frases del contexto casi verbatim —lo cual beneficia específicamente al componente léxico (35 %) de nuestra Fidelidad híbrida—, mientras que en las métricas de calidad general (BERTScore, Relevancia) la redacción más fluida de DeepSeek no se ve penalizada. El punto arquitectónicamente relevante es doble: (i) la pipeline SIRCA-RAG tolera el reemplazo del generador sin ajustes adicionales, y (ii) la elección del generador sí importa para la Fidelidad específicamente, no para la calidad de generación en general. A diferencia de una corrida temprana de este mismo experimento, esta corrida no registró respuestas vacías en ninguno de los dos modelos (0/50 cada uno), tras el fix de reintento descrito en la Limitación (vii).

5.2. Verificación Cruzada

Queríamos estar seguros de que nuestra métrica de Fidelidad no nos estuviera mintiendo. Así que aplicamos la técnica *LLM-as-judge* [27], poniendo al propio Gemma-4 a calificar del 0 al 4 qué tan bien había respondido DeepSeek respecto a los textos entregados. Hicimos a propósito que el modelo evaluador fuera de otra familia para evitar sesgos amigables. El resultado cualitativo es alentador: 43 de las 50 respuestas sacaron puntaje perfecto (4/4), una obtuvo 3, cinco obtuvieron 2, y una sola recibió cero por no aportar información útil. Ese 86 % de calificaciones perfectas deja, sin embargo, muy poca varianza en el juez para una correlación formal: el coeficiente de Pearson entre el puntaje del juez y nuestra métrica algorítmica resultó bajo y no significativo ($r=0,056$, $p=0,70$), esperable cuando una de las dos variables está concentrada casi por completo en su valor máximo (efecto techo).

Lo interesante aquí es la brecha cruda de los números. El juez promediaba notas altas (0,925 normalizado), pero nuestra métrica era mucho más dura (0,517). Esto ocurrió porque diseñamos nuestra fórmula para ser implacable con los parafraseos médicos: preferimos que el sistema nos reporte una baja nota antes de dar por válida una frase que suene “parecida” pero que podría contener un error clínico. Reconocemos que ningún juez artificial va a reemplazar el rigor toxicológico de un farmacéutico humano; el ejercicio funciona mejor como filtro cualitativo grueso (detectar respuestas sin sustento) que como validación cuantitativa estricta de la Fidelidad, dado el efecto techo observado.

Tabla 4. Ablation de seis configuraciones (50 consultas). Recuperación: metodología basada en el agente con el evaluador CRAG calibrado por sigmoide (script `run_perquery_agent_ablation.py`). Fidelidad: reportada para `full` y `no_reranker` con generación DeepSeek V4-Flash (script `run_n5_fidelity_wilcoxon.py`); “n/d” indica configuraciones cuya re-ejecución LLM por-consulta queda como trabajo futuro (Limitación iii). Negrita = mejor; subrayado = peor por columna. [†]`dense_only` coincide con `full` en recuperación porque tras el reordenamiento el Top-10 es el mismo en las 50 consultas (invariante a α cuando el cross-encoder domina); `no_classifier` no comparte esa invariancia (ver Sección 5.4).

Config.	C.Prec.	C.Recall	MRR	NDCG@10	Fidel.	Δ Fidel.
+ <code>full</code>	0,411	0,482	0,825	0,741	0,566	—
<code>dense_only</code> [†]	0,411	0,482	0,825	0,741	n/d	n/d
<code>sparse_only</code>	0,402	<u>0,466</u>	0,752	0,666	n/d	n/d
<code>no_reranker</code>	0,418	<u>0,476</u>	0,869	0,751	<u>0,465</u>	−17,8 %
<code>no_crag</code>	0,431	0,511	0,851	0,772	n/d	n/d
<code>no_classifier</code>	0,479	0,558	0,862	0,833	n/d	n/d

5.3. Hallazgos al Desarmar el Sistema

Al quitar piezas una por una (Tabla 4), saltaron a la vista cuatro verdades incómodas pero útiles. Primero, el módulo de reordenamiento es literalmente el escudo del sistema. Cuando lo apagamos, la Fidelidad se desplomó un 17,8 % relativo (de 0,566 a 0,465), diferencia estadísticamente significativa por Wilcoxon pareado ($p=0,00023$; Sec. 5.4). Resulta que la fusión inicial sí trae textos relevantes a la parte alta de la lista, pero vienen acompañados de “falsos amigos” que terminan engañando al generador si el reordenador no los filtra a tiempo. Segundo, la búsqueda por palabras clave sola (**sparse_only**) resultó ser la configuración más débil en las cuatro métricas de recuperación (C.Prec. 0,402, C.Recall 0,466, MRR 0,752, NDCG@10 0,666, todas el peor valor por columna): sin el componente denso, BM25 pierde los sinónimos y las variantes de redacción de las 50 consultas. Tercero, y más incómodo todavía: desactivar el clasificador de preguntas (**no_classifier**) *mejora* la recuperación de forma significativa frente a **full** —C.Prec. +16,5 % ($p=0,007$), C.Recall +15,8 % ($p<0,001$) y NDCG@10 +12,4 % ($p=0,003$)—, lo que sugiere que el α fijo por categoría (0,3/0,7/0,5) que asigna el clasificador está peor calibrado que un compromiso fijo de $\alpha=0,6$ para este benchmark; discutimos esta tensión en la Sección 5.4. Cuarto, **dense_only** sí produce exactamente el mismo Top-10 que **full** en las 50 consultas ($n_{\neq}=0$): una vez que el cross-encoder reordena, el sesgo inicial hacia la búsqueda densa pura resulta indiferente. Mirando el reloj, la búsqueda nos toma apenas ~ 1810 ms procesar en CPU, y la redacción tarda entre 10 y 30 segundos usando el servidor de DeepSeek.

5.4. Significancia Estadística de los Deltas del Ablation

Las diferencias entre configuraciones en la Tabla 4 son estimadores puntuales y podrían deberse al azar. Para descartarlo, corrimos pruebas de Wilcoxon signed-rank pareadas sobre los valores per-consulta (50 consultas, test bilateral, dos colas) entre cada variante del ablation y la configuración **full**. La Tabla 5 sintetiza los p -valores para Context Precision, Context Recall, MRR y NDCG@10.

El cuadro estadístico nos obliga a ir más despacio. **sparse_only** no solo tiene el Recall agregado más bajo (0,466 frente a 0,482 de **full**); la diferencia tampoco alcanza significancia a nivel per-consulta ($p=0,523$ en C.Recall, $n_{\neq}=40$): BM25 sin el componente denso pierde en unas consultas y gana en otras, y el neto no se distingue del azar pese a ser consistentemente el peor promedio. **dense_only** sí produce exactamente el mismo Top-10 que **full** ($n_{\neq}=0$, marcada con “—”): el reordenador cross-encoder vuelve la recuperación final indiferente a partir de qué α arranca la fusión. El hallazgo que rompe la intuición es **no_classifier**: a diferencia de **dense_only**, aquí sí hay una diferencia real y *significativa* contra **full** en tres de cuatro métricas (C.Prec. $p=0,007$, C.Recall $p<0,001$, NDCG@10 $p=0,003$; MRR no significativo, $p=0,307$), y en la dirección contraria a la esperada: usar un α fijo de 0,6 para todas las consultas recupera mejor que el α por categoría que asigna el clasificador. Esto no invalida la utilidad del clasificador

Tabla 5. p -valores Wilcoxon signed-rank (bilateral) contra **full**, calculados sobre métricas de recuperación per-consulta con la misma metodología basada en el agente que la Tabla 4. La prueba de significancia sobre Fidelidad se reporta separadamente para la comparación central **full** vs **no_reranker** (dos párrafos abajo, $p=0,00023$; script `run_n5_fidelity_wilcoxon.py`); extenderla a las seis configuraciones exige re-ejecutar el LLM por cada una y queda como trabajo futuro. “—” indica configuraciones cuyo Top-10 recuperado es idéntico a **full** ($n_{\neq}=0$ en las cuatro métricas). $n_{\neq}$ = número de consultas con diferencia no nula en la columna C.Recall (cada métrica tiene su propio $n_{\neq}$; se reporta el de C.Recall como referencia).

Config.	$n_{\neq}$	C.Prec.	C.Recall	MRR	NDCG@10
dense_only	0	—	—	—	—
sparse_only	40	0,450	0,523	0,241	0,100
no_reranker	24	0,637	0,786	0,345	0,695
no_crag	5	0,043	0,043	0,068	0,043
no_classifier	20	0,007	0,0004	0,307	0,003

para otros fines (p. ej. explicabilidad de la decisión de enrutamiento), pero sí indica que su calibración actual de α (0,3/0,7/0,5 por categoría) no está optimizada para este benchmark y merece un barrido de hiperparámetros en trabajo futuro. **no_crag** sí difiere de **full**, aunque en solo 5 de 50 consultas según C.Recall ($p=0,043$, significativo al 95 %): al deshabilitar CRAG esas consultas dejan de disparar REFINAR/BÚSQUEDA_WEB y el contexto final que recibe el generador cambia; en el resto de consultas CRAG acepta el mismo Top-10 en ambas configuraciones. La lectura de conjunto es que, al nivel de recuperación, el ablation sí revela diferencias reales y en algunos casos contraintuitivas —no todas las configuraciones son estadísticamente equivalentes—, pero el impacto más consistente y arquitectónicamente central del ablation sigue viviendo en la Fidelidad, donde quitar el reordenador cuesta un $-17,8\%$ relativo (Tabla 4), una métrica de generación que las pruebas de recuperación no alcanzan a capturar. Para verificar que esa caída no es ruido, aplicamos una prueba de Wilcoxon signed-rank pareada sobre la Fidelidad per-consulta entre **full** y **no_reranker** (con generación DeepSeek): la diferencia es estadísticamente significativa ($p=0,00023$ a dos colas; $p=0,00012$ a una cola, con las 50/50 consultas registrando una diferencia no nula). Es decir, a diferencia de algunas métricas de recuperación, la contribución del reordenador a la Fidelidad —la afirmación central del artículo— sí supera la prueba de significancia de forma robusta.

Nota sobre corridas y valor absoluto de la Fidelidad. La Fidelidad de DeepSeek en la comparación cross-LLM (Tabla 3, 0,517) difiere de la Fidelidad de **full** en la Tabla 4 (0,566) porque provienen de corridas distintas de la API comercial: la Tabla 3 usa la ejecución pareada con Gemma-4, mientras que la Tabla 4 emplea una ejecución dedicada del ablation. El resultado único reproducible entre corridas —y el que sustenta la conclusión del artículo— es la *dirección y significancia* de las diferencias, no el valor absoluto de las métricas.

5.5. El Engaño de la Normalización

Tropezamos con un obstáculo técnico enorme a medio camino. La herramienta de evaluación que estábamos usando tenía la costumbre de estirar los puntajes de cada bloque de texto de 0 a 1. Esto significa que, incluso si todos los textos encontrados eran basura, el "menos malo" recibía un 1,0 perfecto. Consecuentemente, el sistema daba luz verde a todo y jamás activaba las búsquedas externas de auxilio. Tuvimos que meter mano en la arquitectura y calibrar los números en crudo usando una curva sigmoide absoluta. Fijamos los márgenes en 0,60 para aprobar y 0,30 para dudar. Eso solucionó el problema de raíz.

Para probar que esto realmente funcionaba, le tiramos al sistema un arsenal de 27 preguntas trampa. Algunas eran sobre plantas que sabíamos que no estaban en la base; otras eran absurdos informáticos como "Vue.js", y otras eran simplemente palabras inconexas. La Tabla 6 muestra cómo se defendió el algoritmo.

Tabla 6. Decisiones del sistema al procesar 27 consultas de estrés. Familia A: Taxones sin datos indexados; Familia B: Temáticas ajenas al dominio botánico; Familia C: Cadenas léxicas degradadas.

Familia	<i>n</i>	ACEPTAR	REFINAR	BÚSQUEDA _ WEB
A. Especies sin datos	9	1	3	5
B. Fuera de dominio	10	0	0	10
C. Confusas	8	4	0	4
Total (<i>probes</i>)	27	5	3	19
Total (<i>benchmark</i> en dominio)	50	35	5	10

El comportamiento observado se alineó con las expectativas teóricas. Frente a temáticas fuera de lugar, el sistema redirigió el 100 % de las veces hacia la búsqueda externa. Al consultar por plantas ausentes en el corpus, en 8 de 9 intentos solicitó reformular la premisa o acudió a internet. Hubo un único bypass con *Senecio canescens*, ocasionado porque el motor recuperó datos de taxones filogenéticamente afines. Sobre el propio *benchmark* en dominio (50 consultas), la calibración absoluta no siempre da ACEPTAR: 35/50 enrutan a ACEPTAR, 5/50 a REFINAR y 10/50 a BÚSQUEDA _ WEB. Interpretamos estas 15 activaciones correctivas como comportamiento correcto y no como falsos negativos: se concentran desproporcionadamente en consultas *exploratorias* y *comparativas* (12/15, 80 %, frente a 51 % en las consultas aceptadas), categorías que por diseño piden síntesis a través de múltiples fuentes en lugar de un dato puntual, y por tanto son más propensas a una recuperación genuinamente ambigua. Preferimos que el sistema declare incertidumbre en esos casos antes que fabricar una respuesta. En síntesis, demostramos de forma empírica que el mecanismo de redirección opera con éxito y que, al reemplazar la normalización intra-batch por la calibración sigmoide absoluta, la ruta correctiva se activa tanto en entradas fuera de distribución como

en consultas en dominio de baja confianza —el bug de la normalización previa había suprimido este segundo caso, indistinguible del comportamiento nominal.

6. Discusión

A la hora de procesar consultas de herbolaria, nos enfrentamos a estructuras heterogéneas. Un usuario puede solicitar "nombres comunes" y concatenar un término académico riguroso como *Uncaria tomentosa*. Como documentamos, la búsqueda léxica es insuperable para capturar nombres latinos, pero el método híbrido se justifica porque el *cross-encoder* interviene para depurar aquellos resultados que carecen de cohesión semántica. Adicionalmente, gestionar múltiples idiomas de forma nativa mediante el espacio vectorial mitigó barreras computacionales considerables.

Si volteamos a ver otros esfuerzos, como el equipo de Monroy Barrios et al. [19], ellos inyectaron a la fuerza textos andinos dentro del cerebro de Llama. Eso da respuestas fluidas, pero si un médico te pregunta de dónde sacaste esa dosis, no hay forma de demostrarlo. Nuestro camino con RAG mantiene los datos afuera, auditables y con un número de referencia rastreable. Creemos que el futuro obvio será fusionar ambos mundos: ajustar un modelo y, encima, ponerle un RAG de protección.

Disponibilidad y limitaciones. El código completo se encuentra publicado en https://github.com/yughiyami/rag_medicinal_plants; existe además una demo interactiva en <https://rag.scn.quest> donde se pueden observar en tiempo real los fragmentos recuperados con sus DOI/PMID y la decisión de enrutamiento CRAG para cada consulta. Listamos a continuación las limitaciones actuales con el fin de que los lectores puedan dimensionar correctamente el alcance de los resultados: (i) el *benchmark* humano-verificado abarca 12 de las 100 especies del corpus; la recuperación fue verificada sobre 42 especies en total (Sec. 5) y el enrutamiento sobre las 9 especies sin datos en índice (Sec. 5.5), pero la evaluación completa de calidad de respuesta sobre las 58 especies restantes exige construir respuestas de referencia adicionales; (ii) las respuestas de referencia actuales fueron elaboradas por los propios autores; aunque la métrica de Fidelidad fue contrastada con un LLM-juez independiente (Sec. 5.2), la validación por un especialista externo en farmacognosia o etnobotánica aún está pendiente, siendo ese el primer requisito antes de cualquier uso clínico o productivo; (iii) probamos la significancia sobre Fidelidad para la comparación central (*full* vs *no_reranker*, $p=0,00023$; Sec. 5.4); extender el test de Fidelidad a las seis configuraciones del ablation requiere re-ejecutar el LLM por cada una y queda como trabajo futuro; (iv) la Fidelidad híbrida (65 % semántico + 35 % léxico) fue contrastada contra un LLM-juez en la Sec. 5.2; el 86 % de calificaciones perfectas del juez sirve como filtro cualitativo grueso, pero la correlación formal no resultó significativa por el efecto techo resultante ($r=0,056$, $p=0,70$), así que esta validación debe leerse como indicativa, no como prueba cuantitativa; la correlación con juicios humanos expertos sigue abierta como pregunta de investigación; (v) la robustez ante distintos LLM fue verificada con un segundo generador (Ce-

rebras Gemma-4-31B); extender esa verificación a otras familias (Llama, Qwen, Mistral) fortalecería la afirmación de generalidad; (vi) los umbrales de calibración ($\sigma_{\text{acc}}=0,60$, $\sigma_{\text{ref}}=0,30$) provienen de la curva sigmoide del cross-encoder y se validaron sobre 27 *probes*; un barrido sistemático sobre un conjunto OOD más amplio permitiría afinar el punto de operación; (vii) una corrida temprana de la evaluación cross-LLM (Sec. 5.1) mostró al generador DeepSeek V4-Flash devolviendo respuestas vacías o truncadas en 8/50 consultas (16 %); diagnosticamos la causa (ausencia de reintento ante contenido vacío en el cliente HTTP) y la corregimos con reintento y backoff exponencial, lo que eliminó el problema por completo (0/50 en la corrida reportada en este artículo); dejamos constancia del hallazgo original porque puede resurgir con otros proveedores de API que fallen de forma similar; (viii) los valores absolutos de las métricas de generación dependen del punto en el tiempo en que se accedió a la API comercial de DeepSeek, por lo que la reproducción exacta puede diferir de los valores aquí reportados; las conclusiones de dirección y significancia sí son estables entre corridas.

7. Conclusiones

A lo largo de este manuscrito delineamos la arquitectura de SIRCA-RAG. Integramos métodos de búsqueda paralela, incorporamos un reordenador estricto, establecimos barreras de calibración matemática absoluta y forzamos al modelo a emplear un razonamiento secuencial antes de sintetizar salidas botánicas bilingües. Tras someter el sistema al acervo de 100 especies curativas peruanas, las métricas fueron concluyentes: superamos por un 18,0 % relativo el Context Recall de los enfoques previos implementados para este marco regional. Constatamos empíricamente que el reordenador constituye el eslabón más crítico de la cadena de confianza; su exclusión reduce la Fidelidad de forma estadísticamente significativa (−17,8 % relativo, $p=0,00023$). Las pruebas de validación cruzada con un segundo generador (Cerebras Gemma-4-31B) confirmaron que la arquitectura tolera el reemplazo del LLM sin cambios de diseño, aunque tres de las cinco métricas de generación —Fidelidad, BERTScore F1 y Relevancia— sí varían de forma estadísticamente significativa según el generador elegido. Observamos, de primera mano, cómo los comportamientos predeterminados del software estándar comprometen las tuberías correctivas si no se interviene directamente en la mecánica de la normalización empírica. Como corolario, la trayectoria futura es evidente: resulta imperativo estructurar paneles con biólogos para auditar las respuestas bajo un estricto escrutinio profesional [12], ampliar el alcance de nuestras pruebas geográficas y, en una dimensión más ambiciosa, ejecutar modificaciones paramétricas sobre los pesos del LLM para internalizar la ontología botánica previo al análisis documental.

Referencias

1. Asai, A., Wu, Z., Wang, Y., Sil, A., Hajishirzi, H.: Self-RAG: Learning to retrieve, generate, and critique through self-reflection. In: Proceedings of the Twelfth Inter-

- national Conference on Learning Representations (2024), <https://openreview.net/forum?id=hSyW5go0v8>
2. Bussmann, R.W., Malca-García, G., Glenn, A., Sharon, D., Chait, G., Díaz, D., Pourmand, K., Jonat, B., Somogy, S., Guardado, G.: Toxicity of medicinal plants used in traditional medicine in Northern Peru. *Journal of Ethnopharmacology* **137**(1), 121–140 (2011). <https://doi.org/10.1016/j.jep.2011.04.071>
 3. Bussmann, R.W., Sharon, D.: Traditional medicinal plant use in Northern Peru: Tracking two thousand years of healing culture. *Journal of Ethnobiology and Ethnomedicine* **2**(1), 47 (2006). <https://doi.org/10.1186/1746-4269-2-47>
 4. Collanqui, E.A., Coaguila, M.E., Flores, A., Apaza, H.: Faithfulness and relevance in stable normative domains: A comparative analysis of CAG vs. RAG. In: *SimBig 2025: Information Management and Big Data. Communications in Computer and Information Science*, vol. 2895, pp. 137–153. Springer (2026). https://doi.org/10.1007/978-3-032-20322-9_10
 5. Cormack, G.V., Clarke, C.L., Buettcher, S.: Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In: *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. pp. 758–759 (2009). <https://doi.org/10.1145/1571941.1572114>
 6. DeepSeek-AI: DeepSeek-V4 technical documentation. Tech. rep., DeepSeek (2026), <https://fe-static.deepseek.com/chat/transparency/deepseek-V4-model-card-EN.pdf>, accessed July 2026
 7. Es, S., James, J., Espinosa-Anke, L., Schockaert, S.: RAGAs: Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv:2309.15217* (2023). <https://doi.org/10.48550/arXiv.2309.15217>
 8. Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, H.: Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997* (2024). <https://doi.org/10.48550/arXiv.2312.10997>
 9. Gemma Team, Google DeepMind: Gemma 4 model card. Tech. rep., Google DeepMind (2026), https://ai.google.dev/gemma/docs/core/model_card_4, accessed July 2026
 10. Gonzales, G.F.: Ethnobiology and ethnopharmacology of *Lepidium meyenii* (Maca), a plant from the Peruvian Highlands. *Evidence-Based Complementary and Alternative Medicine* **2012**, 193496 (2012). <https://doi.org/10.1155/2012/193496>
 11. Gu, Y., Tinn, R., Cheng, H., Lucas, M., Usber, N., Liu, X., Naumann, T., Gao, J., Poon, H.: Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare* **3**(1), 1–23 (2021). <https://doi.org/10.1145/3458754>
 12. Heinrich, M., Jalil, B., Abdel-Tawab, M., Echeverria, J., Kulic, Z., McGaw, L.J., Pezzuto, J.M., Sözl, A., Wagner, H.: Best practice in the chemical characterisation of extracts used in pharmacological and toxicological research—the ConPhyMP-guidelines. *Frontiers in Pharmacology* **13**, 953205 (2022). <https://doi.org/10.3389/fphar.2022.953205>
 13. Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y.J., Madotto, A., Fung, P.: Survey of hallucination in natural language generation. *ACM Computing Surveys* **55**(12), 1–38 (2023). <https://doi.org/10.1145/3571730>
 14. Johnson, J., Douze, M., Jégou, H.: Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data* **7**(3), 535–547 (2021). <https://doi.org/10.1109/TBDATA.2019.2921572>
 15. Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., Yih, W.t.: Dense passage retrieval for open-domain question answering. In: *Proceedings*

- of the 2020 Conference on Empirical Methods in Natural Language Processing. pp. 6769–6781 (2020). <https://doi.org/10.18653/v1/2020.emnlp-main.550>
16. Lee, J., Yoon, W., Kim, S., Kim, D., Kim, S., So, C.H., Kang, J.: Bio-BERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics* **36**(4), 1234–1240 (2020). <https://doi.org/10.1093/bioinformatics/btz682>
 17. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.t., Rocktäschel, T., Riedel, S., Kiela, D.: Retrieval-augmented generation for knowledge-intensive NLP tasks. In: *Advances in Neural Information Processing Systems*. vol. 33, pp. 9459–9474 (2020), <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>
 18. Lock, O., Perez, E., Villar, M., Flores, D., Rojas, R.: Bioactive compounds from plants used in peruvian traditional medicine. *Natural Product Communications* **11**(3), 315–337 (2016), <https://pubmed.ncbi.nlm.nih.gov/27169179/>
 19. Monroy Barrios, J.E., Paco Cusi, E.M., Portella Huincho, M.A., Valdivia Eguiluz, J.M., Basurco Zapata, G.F., Jara Rosales, F.: Fine-tuning of small language models for ecological monitoring: A comparative analysis based on perplexity. In: *SimBig 2025: Information Management and Big Data. Communications in Computer and Information Science*, vol. 2895, pp. 300–313. Springer (2026). https://doi.org/10.1007/978-3-032-20322-9_21
 20. Nogueira, R., Cho, K.: Passage re-ranking with BERT. arXiv preprint arXiv:1901.04085 (2019). <https://doi.org/10.48550/arXiv.1901.04085>
 21. Robertson, S., Zaragoza, H.: The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval* **3**(4), 333–389 (2009). <https://doi.org/10.1561/15000000019>
 22. Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., Wei, F.: Multilingual E5 text embeddings: A technical report. arXiv preprint arXiv:2402.05672 (2024). <https://doi.org/10.48550/arXiv.2402.05672>
 23. Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E.H., Le, Q.V., Zhou, D.: Chain-of-Thought prompting elicits reasoning in large language models. In: *Advances in Neural Information Processing Systems*. vol. 35, pp. 24824–24837 (2022), https://proceedings.neurips.cc/paper_files/paper/2022/hash/9d5609613524ecf4f15af0f7b31abca4-Abstract-Conference.html
 24. Xiong, G., Jin, Q., Lu, Z., Zhang, A.: Benchmarking retrieval-augmented generation for medicine. In: *Findings of the Association for Computational Linguistics: ACL 2024*. pp. 6233–6251 (2024). <https://doi.org/10.18653/v1/2024.findings-acl.372>
 25. Yan, S.Q., Gu, J.C., Zhu, Y., Ling, Z.H.: Corrective retrieval augmented generation. arXiv preprint arXiv:2401.15884 (2024). <https://doi.org/10.48550/arXiv.2401.15884>
 26. Zhang, T., Kishore, V., Wu, F., Weinberger, K.Q., Artzi, Y.: BERTScore: Evaluating text generation with BERT. In: *Proceedings of the Eighth International Conference on Learning Representations* (2020), <https://openreview.net/forum?id=SkeHuCVFDr>
 27. Zheng, L., Chiang, W.L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E.P., Zhang, H., Gonzalez, J.E., Stoica, I.: Judging LLM-as-a-judge with MT-Bench and chatbot arena. In: *Advances in Neural Information Processing Systems*. vol. 36 (2023), https://proceedings.neurips.cc/paper_files/paper/2023/hash/91f18a1287b398d378ef22505bf41832-Abstract-Datasets_and_Benchmarks.html